

基于 iTransformer 与 XAI 的电力负荷时序预测研究：从常规到极端天气场景

1.引言与研究背景

1.1 研究背景与痛点

近年来极端天气事件频发，极端天气事件下的气象要素剧烈突变对电网的供需平衡与调度运行造成了巨大冲击。准确的负荷预测是电网安全稳定运行的基础。特别是极端天气场景下能够天气预测做出负荷的正确预测，对于电网的安全稳定运行有着重要作用，也是目前智慧电网建设亟待攻克的核心痛点。

1.2 现有方法的局限性

电网负荷预测有着很强的时序周期性特征，且与多种气象预测因素有着复杂的非线性耦合关系。传统机器学习在电网负荷预测中通常难以学习到全局的时序特征，负荷预测的误差和不稳定都有所不足。传统深度学习算法又难以兼顾准确性与可解释性。

1.3 本文的研究与贡献

为解决以上痛点，本文基于 tetuan 市三个配电区域的一年负荷和天气数据和比利时电网负荷数据与欧洲中期天气预报中心的北纬 50.0,东经 4.0 天气数据作为数据集进行模型训练实验。基于过往七日的天气数据对未来 24 小时电网负荷进行预测。

本文首先通过训练基于时序预测特性优化的 autoformer 模型对比传统模型随机森林，二者在 24 小时的预测效果上并未拉开，说明基础的注意力机制对于电网时序的预测效果有限。并且 autoformer 平滑预测特性导致在极端天气条件下 autoformer 倾向于基于天气数据复制过往平滑曲线，对于极端天气下的独特负荷曲线学习能力较弱。

基于此，本文选用了 DLinear 和 iTransformer 模型做进一步研究：

1.验证了极简线性架构在负荷时序捕获上的优越性：DLinear 的预测能力显著超越了 autoformer 模型，证明了相对于多层神经网络增强的模型对于非线性函数的处理能力，负荷预测更注重对时序信息的捕获能力。

2.基于 iTransformer 突破了注意力、多层神经网络对非线性函数的处理能力和时序分析之间的取舍：iTransformer 的预测能力进一步提升，基于输入 token 的改进，解决了简单的时间点之间关联计算的时序特征提取，且改进注意力机制解决了跨变量间的直接关联导致的噪声。

3.本文引入了可解释性 AI (XAI) 打破了深度学习的黑箱：鉴于神经网络可解释性缺失和本文工程上的需要，本文对 transformer 衍生模型[2]均引入 XAI 技术。使用 SHAP 分析各特征的贡献度，对复杂的模型的决策过程进行归因分析，量化了各类天气特征在常态与极端场景下对预测结果的具体影响，并分析了 autoformer 和 iTransformer 在同一场景下的特征提取的共同点和分歧。




图 1-1 项目流程图

2.数据处理与基础实验：传统模型与 Autoformer 的局限性

2.1 多变量气象—负荷数据集构建与预测任务设置

高质量、连续且时间对齐的数据是开展电力负荷时序预测的基础。本文首先对原始比利时电力负荷数据进行清洗，剔除公开数据中由既有模型生成的预测负荷字段，仅保留真实负荷数据（Total Load）。随后，将负荷数据与欧洲中期天气预报中心提供的北纬 50.0°、东经 4.0°附近小时级气象数据进行时间对齐与合并。

合并后的气象变量主要包括海平面气压、表面太阳辐射向下通量、总云量、总降水量、2 米气温和 10 米风速等。经过缺失值检查、时间格式统一和小时级聚合后，共计 100994 条数据，形成比利时多变量气象—负荷数据集，以下称为数据集 1。

本文以真实负荷 Total Load 为唯一预测目标，采用 MS 模式，即多变量输入、单变量输出。模型输入包括历史负荷及同期多种气象特征，输出仅为未来负荷序列。该设置既保留了气象信息对负荷预测的辅助作用，又使评价指标集中于实际负荷预测性能。

在数据集 1 中，模型输入序列长度设置为： $L = 168$ 即利用过去 7 天的小时级历史负荷和气象数据预测未来状态。预测序列长度设置为： $T = 24$ 即一次预测未来 24 小时的系统负荷。168 小时的输入窗口同时覆盖日周期和周周期信息，适合日前负荷预测任务。

为检验实验结论是否仅依赖于比利时数据，本文进一步引入 Kaggle 公开的 Tetuan City Power Consumption 数据集。该数据集包含 Tetuan 市三个配电区域的功耗数据以及当地气温、湿度、风速、总散射日射量和散射辐射量等气象变量，共计 52417 条数据。为减少不同区域负荷之间的互相关干扰，本文仅保留区域 1

负荷作为预测目标，并隐藏区域 2 和区域 3 负荷，形成数据集 2。

由于数据集 2 仅包含约一年的观测数据，本文未进一步构建极端天气子集，而仅将其用于检验不同模型在常规天气条件下的预测能力。考虑到其时间跨度和样本规模，数据集 2 的输入序列长度设置为： $L = 72$ 即使用过去 3 天的数据预测未来 24 小时负荷，预测长度仍设置为 $T = 24$ ：两个数据集均按照时间顺序划分训练集、验证集和测试集，避免随机打乱造成未来信息泄漏。训练过程中采用训练集损失进行早停，并在独立测试集上计算 MSE 和 MAE （本文的 MSE 和 MAE 均作了标准化处理）。

本文统一 $seed = 2021$ ，本文按照时间顺序将数据划分为训练集、验证集和测试集，比例分别为 70%、10%和 20%。

2.2 传统机器学习基线测试与多步时序预测困境

作为传统机器学习基线，本文首先测试随机森林模型。随机森林由 Breiman 提出，通过集成多棵决策树提高预测稳定性[1]。随机森林通过对特征空间进行多次划分，并对多棵决策树的输出进行集成，可以有效拟合一般的非线性映射关系，但其本身不包含显式的时序依赖建模机制。本文的随机森林模型 24 小时预测方法为直接将输出设为 24 维的代表未来 24 小时负荷的张量进行训练。

在数据集 1 的常规天气预测任务中，随机森林取得： $MSE = 0.2180$ ， $MAE = 0.3615$ 其表现明显弱于后续的 DLinear 和 iTransformer 模型。

本文认为，随机森林在本任务中的局限主要体现在两个方面。首先，决策树通常根据当前输入窗口中的统计特征进行分段判断，难以像时序神经网络一样直接建模不同时间步之间的长期依赖关系。其次，回归树叶节点的预测结果通常是节点内训练样本目标值的平均值，因此，当测试样本出现训练集中较少见的负荷尖峰时，其输出容易向已有样本的平均模式收缩。

在 24 步多步预测任务中，这种局限表现为负荷峰谷变化被压缩，预测曲线相对保守。尤其是在气象条件快速变化时，随机森林难以从未见过的变量组合中外推出新的负荷变化模式。因此，虽然随机森林可以作为结构简单、训练快速的基线模型，但难以满足高精度日前负荷预测的需要。

2.3 Autoformer 的周期建模机制与过度平滑现象

为提高长序列预测能力，本文进一步引入针对时间序列任务设计的 Autoformer 模型。Autoformer 由 Wu 等提出[3]，通过序列分解机制，将输入分解为趋势项和季节项，并利用基于快速傅里叶变换实现的自相关机制寻找不同时间位置之间的周期依赖。

然而，在数据集 1 的常规天气实验中，Autoformer 并未表现出预期优势，其测试结果为： $MSE = 0.2343$ ， $MAE = 0.3525$ 其 MSE 甚至略高于随机森林。

通过观察真实负荷曲线和模型预测曲线，本文发现 Autoformer 输出存在较明显的过度平滑现象。预测结果能够描述负荷曲线的总体走势，但对日内峰谷变化和局部突变的拟合相对不足。

这一现象可能与 Autoformer 的周期模式提取方式有关。电力负荷虽然具有明显的 24 小时周期和周周期，但其短时变化还会受到温度、风速、降水以及社会活动等外部因素影响。当局部变化无法被稳定的历史周期解释时，过度强调周期相关性可能使模型倾向于输出较平滑的平均变化轨迹。

因此，Autoformer 在本研究中的局限并不意味着其自相关机制在所有时序任务中无效，而是表明：在本文的多变量气象—负荷预测任务中，仅依赖历史周期结构不足以充分捕获复杂的日内波动和外部气象扰动。

综上，随机森林的叶节点均值输出和 Autoformer 的预测平滑化均限制了其负荷预测精度，有必要进一步引入能够保留基础时序规律、同时建模变量间关系的预测架构。

Autoformer 参数如下： $label_len = 48, learning_rate = 0.0001, batch_size = 32, train_epochs = 10, pred_len = 24, seq_len = 168$ ，早停轮数为 3

3 DLinear 与 iTransformer 在常规天气下的性能分析

3.1 数据集 1 上的模型性能对比

在数据集 1 的常规天气场景中，四种模型的预测结果如下。

表 3-1 数据集 1 常规天气预测结果

模型	MSE	MAE
iTransformer	0.0644	0.1801
DLinear	0.0927	0.2180
Random Forest	0.2180	0.3615
Autoformer	0.2343	0.3525

DLinear 取得了 $MSE = 0.0927, MAE = 0.2180$ 的结果，显著优于随机森林和 Autoformer。DLinear 通过对趋势项和季节项进行线性映射，使用相对简单的结构完成多步预测[4]。其优异表现说明，在常规天气条件下，电力负荷具有高度可利用的周期和趋势规律，复杂的非线性结构并非获得良好预测结果的必要条件。

这一结果同时说明，模型复杂度与预测精度并不必然呈正相关。如果模型架构不能有效保留负荷序列中的关键时间结构，增加模型复杂度反而可能引入额外噪声或产生过度平滑。

iTransformer 在数据集 1 上取得了最低的预测误差： $MSE = 0.0644, MAE = 0.1801$ 。相较于 DLinear，iTransformer 的 MSE 降低约 30.5%。iTransformer 由 Liu 等提出[5]，与传统 Transformer 将每个时间点视为一个 token 不同，iTransformer 将每个变量的完整历史序列视为一个 token，从而在变量维度上计算注意力关系。该设计使模型可以直接学习历史负荷、温度、风速、气压等变量之间的关联，同时由前馈网络完成各变量内部的时间模式提取。

实验结果表明，在保留历史周期信息的基础上，进一步建模气象变量与负荷之间的复杂关联能够明显提高预测精度。但仅凭误差指标不能直接证明模型学习到了真实的物理因果关系，因此，后文将结合 SHAP 和模型权重变化进一步分析其决策依据。

DLinear 和 iTransformer 的参数与 Autoformer 完全相同： $label_len = 48, learning_rate = 0.0001, batch_size = 32, train_epochs = 10, pred_len = 24, seq_len = 168$

3.2 数据集 2 上的外部验证

为检验数据集 1 中的模型排序是否具有一定稳定性，本文在 Tetuan 数据集

上重复进行了常规天气预测实验，结果如下。

表 3-2 数据集 2 常规天气预测结果

模型	MSE	MAE
iTransformer	0.0677	0.1347
DLinear	0.1036	0.1819
Autoformer	0.2282	0.3416
Random Forest	0.4565	0.6159

数据集 2 上的实验结果与数据集 1 基本一致：iTransformer 保持第一，DLinear 排名第二，Autoformer 和随机森林的误差相对较高。

其中，iTransformer 在数据集 2 上取得 $MSE = 0.0677$, $MAE = 0.1347$ 的结果，说明其优势并非仅出现在比利时负荷数据上。DLinear 仍然表现出较强的基础预测能力，进一步支持了常规负荷序列具有明显周期和趋势结构的判断。

随机森林在数据集 2 上的表现下降较为明显，表明在不同地区、不同数据分布下，其对复杂时间关系的建模能力和外推能力相对有限。Autoformer 的预测结果仍存在一定平滑化倾向，其表现未能超过结构更加简单的 DLinear。

需要指出的是，数据集 2 中的模型均在 Tetuan 数据上重新训练，因此该实验验证的是不同模型在另一数据集上的适用性和排名稳定性，而不是模型在不重新训练条件下的跨区域迁移能力。

3.3 常规天气实验小结

两个数据集均表明，iTransformer 取得最优性能，DLinear 稳定排名第二；Autoformer 和随机森林整体处于较低性能水平，但二者的具体排序会随数据集和评价指标变化。DLinear 的良好表现表明，常规负荷预测首先是一个具有强时间规律的问题；iTransformer 在此基础上的进一步提升则说明，多变量之间的交互关系同样具有预测价值。

因此，本文对常规天气实验的主要结论是：稳定的负荷周期和趋势构成了负荷预测的基础，而变量维度注意力机制能够在此基础上进一步提取气象特征与目标负荷之间的复杂关联。

4 极端天气条件下的模型性能分析

4.1 极端天气数据集构建

为研究模型在复杂气象条件下的预测表现，本文从数据集 1 中进一步筛选极端天气事件。考虑到比利时当地的气候限制和模型训练的需要，本文规定极端天气判定条件包括： $temperature < 0^{\circ}\text{C}$ 或 $temperature > 35^{\circ}\text{C}$ 以及小时降水量超过 5mm/h 、风速超过 15m/s 等情况。只要某一时刻满足至少一项极端天气条件，即将其标记为极端天气时刻。

考虑到负荷变化可能存在一定滞后，且时序预测模型需要连续历史窗口，本文不仅保留极端天气发生时刻，还保留极端事件所在的完整日期及其之前 7 天的数据，从而形成具有连续时间上下文的极端天气数据集，共计 8689 条数据。

极端天气数据集同样按照时间顺序划分训练集、验证集和测试集。各模型在极端天气训练集上训练，并在未参与训练的后段极端天气测试集上评价。

因此，常规天气实验和极端天气实验是两个分别训练、分别测试的预测任务，而不是将同一个常规天气模型直接迁移到极端天气测试集。

4.2 极端天气下的模型性能对比

表 4-1 极端天气场景预测结果

模型	MSE	MAE
iTransformer	0.1756	0.2983
DLinear	0.2009	0.3295
Random Forest	0.3510	0.4798
Autoformer	0.4046	0.4630

在极端天气场景下，所有模型的误差水平都高于其各自在常规天气任务中的结果，说明极端气象条件下的负荷变化更加复杂。但由于两个实验使用了不同的训练集和测试集，这种数值差异只能说明极端天气任务具有更高预测难度，不能直接解释为同一个模型的性能下降比例。

随机森林在极端天气测试集上的MSE达到 0.3510。极端气象变量组合在训练样本中出现频率较低，树模型很难对已有特征划分范围之外的变化进行有效外推，因此容易低估负荷尖峰。

Autoformer 取得MSE为 0.4046，是四种模型中最高的。其预测曲线仍然表现出明显平滑化特征。当极端天气打破常规周期并产生非周期负荷变化时，基于历史相关模式生成的预测难以及时响应局部突变。

DLinear 的MSE为 0.2009，仍然排名第二。这说明即使在极端天气条件下，历史趋势和周期信息仍然具有一定预测价值，但单纯依靠线性映射无法充分描述外部气象变量对负荷的复杂影响。

iTransformer 取得最低MSE和MAE，说明其在极端天气数据分布中仍然具有最强的综合预测能力。其优势并不表现为完全消除极端天气带来的预测困难，而是能够在不同天气分布下维持稳定的模型排名和较低的绝对误差。

极端数据集中 *batch_size* 改为 8：*label_len* = 48, *learning_rate* = 0.0001, *batch_size* = 8, *train_epochs* = 10, *pred_len* = 24, *seq_len* = 168

4.3 关于跨场景MSE增长率的说明

本文不采用常规天气MSE与极端天气MSE之间的增长率评价模型鲁棒性。在本实验中缺乏明确的比较含义。

这是因为常规实验和极端实验不仅测试集分布不同，训练集也不同。常规天气模型和极端天气模型分别在各自数据分布上完成训练，相当于两个具有不同数据生成机制和不同预测难度的任务。直接计算二者误差增长率，类似于将两个不同科目的成绩直接计算“下降比例”，会混淆模型能力、样本分布和任务难度三种因素。

因此，本文主要从以下两个方面评价模型在不同天气场景下的稳定性：

第一，在每个任务内部比较各模型的绝对MSE和MAE；第二，观察模型在不同任务中的排名及模型间误差差距是否保持稳定。

在两个任务中，iTransformer 均排名第一，DLinear 均排名第二，而随机森林和 Autoformer 均明显落后。这种稳定排序表明，iTransformer 的优势并非由某一个测试集上的偶然结果造成。

需要说明的是，当前实验尚未直接测试“使用常规天气训练得到的同一个模型，在极端天气测试集上的表现”，因此本文不将现有结果解释为严格的零样本跨分布泛化结论。

5 基于特征归因与权重变化的模型行为分析

5.1 SHAP 归因方法

为进一步分析不同模型产生性能差异的原因,本文采用 SHAP 方法计算各输入特征对预测结果的贡献。SHAP 由 Lundberg 等提出[6],基于合作博弈思想,通过比较某一特征加入前后模型输出的变化,估计该特征对预测结果的边际贡献。

对于本文的 MS 预测任务,SHAP 可以用于分析历史负荷、风速、温度、降水、气压和辐射等变量在模型预测中的相对作用,本文中的 feature0~6 分别为 u10,t2m,msl,ssrd,tcc,tp,Total Load。

需要强调的是,SHAP 值描述的是模型对某项输入信息的利用程度,而不是变量对实际负荷的物理因果影响。因此,某一气象变量具有较高 SHAP 值,只能说明模型在当前数据和预测任务中较多依赖该变量,不能直接说明该变量在现实中必然是负荷变化的主要原因。

5.2 Autoformer 的特征依赖与平滑化预测




图 5-1 极端天气数据集下 Autoformer 基于 loss 函数为 mse 的结果

Autoformer 在标准 MSE 损失下的 SHAP 结果表明,历史负荷仍然是模型预测的重要信息来源,而部分气象变量的贡献相对有限。这与 Autoformer 在预测曲线中呈现出的周期复制和平滑化特征相一致。

历史负荷在日前预测中占据较高贡献本身是合理的,因为电力需求具有明显的日周期和周周期。问题并不在于模型使用历史负荷,而在于当气象条件发生明显变化时,模型是否能够相应调整历史规律与外部气象变量之间的贡献关系。

在本文极端天气任务中,Autoformer 对突变负荷的响应仍然不足。这表明,其对历史周期模式的利用没有充分转化为对复杂外部扰动的适应能力。

5.3 指数损失下 Autoformer 的特征集中现象




图 5-2 极端天气数据集下 Autoformer 基于 loss 函数为指数损失的结果

在采用指数惩罚损失训练 Autoformer 后，模型的 SHAP 特征分布出现明显变化。历史负荷和总降水量的贡献接近，并显著高于其他变量，其余气象变量的重要性接近于零。

这一结果说明，指数损失确实改变了 Autoformer 的特征利用策略。由于大误差样本会产生远高于普通样本的训练梯度，模型倾向于寻找少数能够快速降低极端误差的变量，并形成高度集中的特征依赖。

但这种集中并不能直接解释为模型发现了正确的物理机制。特别是 iTransformer 在极端天气场景中的 SHAP 结果显示，降水并不是其最重要的气象输入，反而具有较低贡献。因此，Autoformer 对降水的集中依赖更可能是一种由损失函数驱动的误差补偿策略，而不是所有模型都认可的普遍气象规律。

5.4 iTransformer 的变量响应与时间权重变化




图 5-3 极端天气数据集下 iTransformer 的结果




图 5-4 常规天气数据集下 iTransformer 的结果

iTransformer 的解释结果呈现出不同的特征使用方式。在极端天气条件下，模型对历史时间规律的相关权重下降，同时提高了对部分气象变量的响应。在已有 SHAP 结果中，风速等变量具有较高贡献，而降水的贡献相对较低。

这一结果表明，iTransformer 没有简单依赖某一个极端天气指标，而是根据当前输入分布重新组织历史负荷与多种气象变量之间的关系。

与 Autoformer 采用指数损失后集中依赖历史负荷和降水不同，iTransformer 的变量贡献更加分散，其预测并非由单一气象变量驱动。这与其将变量视为 token、在变量维度计算注意力关系的架构特点相一致。

结合预测指标和解释结果，本文认为 iTransformer 的优势主要体现为：当负

荷时间规律发生变化时，模型能够降低对固定历史模式的依赖，并重新利用与当前场景相关的输入变量。

6 损失函数消融实验

6.1 损失函数设计

为了研究 Autoformer 的极端天气预测误差是否能够通过优化目标调整得到缓解，本文分别测试MAE、MSE和自定义指数惩罚损失。

MAE定义为： $L_{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$ ，MAE对误差采用线性惩罚，对大误差的敏感程度相对较低，其统计意义更接近于估计条件中位数。

MSE定义为： $L_{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$

MSE通过平方项提高大误差样本的损失贡献，因此相较于MAE更重视少量较大的预测偏差。

本文进一步设计指数惩罚损失： $L_{exp} = \frac{1}{N} \sum_{i=1}^N (2^{\alpha|y_i - \hat{y}_i|} - 1)$ （本文中 loss 相对较小取 $\alpha = 2$ ）

该损失使误差越大的样本获得越高的梯度权重，其设计目的不是提高整体收敛速度，而是增强模型对极端预测偏差的关注。

6.2 损失函数实验结果

表 6-1 不同损失函数对极端天气预测性能的影响

模型	损失函数	测试 MSE	测试 MAE
Autoformer	MAE	0.4059	0.4724
	MSE	0.4046	0.4630
	指数惩罚	0.3718	0.4556
iTransformer	MAE	0.1759	0.2985
	MSE	0.1756	0.2983
	指数惩罚	0.1788	0.3072

对于 Autoformer，使用MAE作为训练损失并未带来性能提升，其MSE由标准MSE训练下的 0.4046 轻微上升至 0.4059。由于MAE对大误差的惩罚仅线性增加，其优化目标未能有效缓解 Autoformer 对突变负荷响应不足的问题。

使用指数惩罚损失后，Autoformer 的 MSE 下降至 0.3718，相较于标准MSE训练降低约 8.1%。该结果说明，提高大误差样本在训练过程中的权重，确实能够部分改善 Autoformer 在极端天气条件下的预测效果。

然而，即使经过指数损失调整，Autoformer 的MSE仍明显高于使用标准MSE训练的 iTransformer。由此可见，损失函数可以改变模型对不同误差样本的关注程度，但可能无法完全弥补模型架构在变量关系建模方面的差异。

对于 iTransformer，MAE、MSE和指数惩罚三种损失下的结果较为接近，其中标准MSE仍取得最优表现。指数惩罚未能进一步提高其性能，反而使MSE由 0.1756 轻微上升至 0.1788。

这一结果表明，更强的大误差惩罚并非对所有模型均有效。当模型本身已经能够较好地建模极端天气下的变量关系时，进一步提高少量大误差样本的权重可能打破原有的整体误差平衡。

6.3 训练轮次与优化方向分析

实验中还观察到，不同损失函数下验证集早停发生的轮次总体接近，没有出现指数损失显著延长或缩短训练过程的现象。

由于不同损失函数的数值尺度和统计意义不同，不能仅根据早停轮次相近就认为三种损失具有完全相同的收敛速度。但这一现象至少说明，在当前训练设置下，损失函数调整主要改变了模型最终优化的误差偏好和特征利用方式，而没有明显改变训练过程的大致持续时间。

结合 SHAP 结果可以进一步发现，指数损失对 Autoformer 的改善伴随着特征贡献向历史负荷和降水集中。这说明其性能提升更接近于损失函数驱动的局部补偿，而不是模型整体多变量表示能力的根本改变。

7 结论与展望

7.1 主要结论

本文围绕常规天气和极端天气条件下的日前电力负荷预测问题，构建了包含历史负荷与多种气象变量的多变量输入、单变量输出预测任务，并比较了随机森林、Autoformer、DLinear 和 iTransformer 四种模型。

实验结果表明，随机森林由于缺少显式的长期时间依赖建模机制，在多步负荷预测中容易产生均值收缩和峰值低估。Autoformer 虽然能够提取周期相关性，但在本文任务中存在较明显的预测平滑化现象，对局部高频波动和极端天气扰动的响应不足。

DLinear 在两个常规天气数据集以及极端天气数据集上均取得较好的预测结果，说明历史周期和趋势仍然是电力负荷预测的重要基础信息。简单线性模型的强基线表现也表明，模型复杂度并不是决定预测精度的唯一因素。

iTransformer 在数据集 1 常规天气、数据集 2 常规天气以及数据集 1 极端天气三个任务中均取得最低的 MSE 和 MAE 。其优势表现为在不同负荷和气象分布下保持稳定的模型排序和较低绝对误差。

解释性分析表明，iTransformer 在极端天气条件下能够降低对固定历史时间模式的依赖，并根据输入场景调整不同气象变量的贡献。相比之下，Autoformer 在指数损失下虽然获得一定性能改善，但同时出现了对历史负荷和降水变量高度集中的特征依赖。

损失函数消融实验进一步说明，优化目标设计能够改变模型对极端误差的关注程度，但其效果受到模型架构能力的限制。指数惩罚损失能够部分改善 Autoformer 的预测性能，但无法使其达到标准 MSE 训练下 iTransformer 的精度。

7.2 研究不足

本文仍存在一定局限。

首先，极端天气样本来源于单一国家和固定气象坐标，实验结果尚不足以证明其在所有电网和气候条件下均成立。

其次，常规天气任务和极端天气任务分别使用各自的数据集进行训练和测试，因此本文能够说明不同模型在两个任务中的性能和排序稳定性，但尚未直接评价同一模型从常规训练分布迁移至极端测试分布时的零样本泛化能力。

第三，SHAP 和模型权重分析反映的是模型预测行为，而不是现实气象变量与负荷之间的因果关系。对于风速、降水等变量的高贡献结果，仍需要结合更多地区数据和电力系统知识进行验证。

最后,自定义指数损失目前仅完成了有限模型和单次实验设置下的验证,其稳定性、最优底数选择以及对不同负荷尺度的敏感性仍需要进一步研究。

7.3 后续研究方向

后续研究可以从三个方向展开。

一是构建普通天气专家模型与极端天气专家模型,并根据日前天气预报对不同模型结果进行动态加权,以提高负荷预测系统对不同气象分布的适应能力。

二是开展同一模型在不同训练分布和固定极端测试集上的对照实验,从而进一步区分模型的基础预测能力、极端场景特化能力和真正的跨分布泛化能力。

三是将日前负荷预测结果引入 IEEE 33 节点配电网强化学习调度环境,使 SAC 在未来真实负荷未知、但日前预测信息可获得的条件下进行训练,并进一步研究预测误差对调度收益和安全约束的影响。该方向能够将负荷预测从单纯的误差优化问题扩展为“预测—决策—安全控制”的完整应用链条。

参考文献

- [1] BREIMAN L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32. DOI: 10.1023/A:1010933404324.
- [2] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems. 2017, 30.
- [3] WU H, XU J, WANG J, et al. Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting[C]//Advances in Neural Information Processing Systems. 2021, 34.
- [4] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(9): 11121-11128. DOI: 10.1609/aaai.v37i9.26317.
- [5] LIU Y, HU T, ZHANG H, et al. iTransformer: Inverted transformers are effective for time series forecasting[C]//International Conference on Learning Representations. 2024.
- [6] LUNDBERG S M, LEE S I. A unified approach to interpreting model predictions[C]//Advances in Neural Information Processing Systems. 2017, 30.

数据来源

- [7] SALAM A, EL HIBAOUI A. Power consumption of Tetouan City[DS/OL]. UCI Machine Learning Repository, 2018[2026-07-29]. DOI: 10.24432/C5B034.
- [8] KESHAV G M. Tetuan City power consumption[DS/OL]. Kaggle[2026-07-29].
- [9] ELIA. Load and load forecasts: Belgian electricity system data[DB/OL]. Elia Grid Data[2026-07-29].
- [10] COPERNICUS CLIMATE CHANGE SERVICE. ERA5 hourly data on single levels from 1940 to present[DS/OL]. Climate Data Store, 2018[2026-07-29]. DOI: 10.24381/cds.adbb2d47.

